

面向无人机航拍小目标检测的轻量化 YOLO11n 改进方法

摘要

无人机航拍图像通常具有俯视视角、目标尺度小、分布密集、遮挡频繁和背景复杂等特点，对实时检测模型的小目标感知和定位能力提出了较高要求。针对 VisDrone 场景下的小目标检测问题，本文以 YOLO11n 为基线，构建并评估了一种结合 P2 高分辨率检测分支、CoordAttention 注意力机制和 960 输入分辨率的轻量化改进模型。该方法通过 P2 分支增强浅层高分辨率特征利用，通过 CoordAttention 引入方向位置敏感信息，并通过较高输入分辨率提高小目标在输入图像和特征图中的有效像素占比。实验结果表明，在当前实验设置下，960 输入分辨率是性能增益的主要来源，P2 分支和 CoordAttention 提供轻量级结构补充。最终，YOLO11n-P2-CA-960 在 VisDrone 验证集上取得最佳 mAP50 0.420 和 mAP50-95 0.252，较 YOLO11n 基线分别提升 9.84 和 6.94 个百分点；单图推理测试达到 19.68 FPS，体现出一定的精度与速度折中。

关键词：无人机目标检测；小目标检测；YOLO11n；CoordAttention；VisDrone

1 引言

无人机平台已广泛应用于交通监控、应急巡检和低空遥感等场景。与地面视角图像相比，无人机航拍图像通常具有俯视视角、尺度变化显著、密集分布和背景复杂等特点。VisDrone2019-DET 数据集包含行人、车辆、非机动车等多类目标，目标尺度小且遮挡频繁，是无人机目标检测研究中的常用基准 [1]。在该类场景中，小目标像素占比较低，目标之间距离较近，容易增加定位、分类和召回难度。

YOLO 系列检测器具有端到端推理、速度快和部署方便等特点，适合实时检测任务。Ultralytics YOLO11 延续了 YOLO 系列的实时检测特性，并提供多种规模模型 [3, 4]。其中，YOLO11n 参数量较小、推理速度较快，适合作为轻量化基线。然而，在 VisDrone 等小目标占比较高的数据集上，轻量模型可能受限于深层特征空间分辨率不足，导致小目标细节信息在多次下采样后被削弱。

为提升 YOLO11n 在无人机小目标检测中的表现，本文从特征尺度、注意力表达和输入分辨率三个方面开展实验研究。主要工作如下：

1. 构建 YOLO11n-P2-CA 模型，在轻量化基线基础上引入 P2 高分辨率检测分支和 CoordAttention 注意力模块，以增强浅层高分辨率特征和位置敏感表达。
2. 系统比较 YOLO11n、YOLO11n-P2、YOLO11n-P2-CA、YOLO11n-P2-CA-960 和 YOLO11n-P2-CA-SmallObjAug，所有数值均来自真实训练日志、验证结果文件或速度测试脚本。
3. 从检测精度、消融实验、模型复杂度、推理速度、类别级结果和可视化案例等方面整理可复现实验材料，并补充 YOLOv8n 与 YOLO11s 外部参考基线，讨论不同改进项在当前实验设置下的作用边界。

2 相关工作

2.1 无人机航拍目标检测

无人机航拍图像具有俯视视角、目标尺度小、密集分布、遮挡频繁和背景复杂等特点。与常规地面目标检测相比，航拍图像中的行人、非机动车和远距离车辆通常只占据较少像素，目标外观信息不足，检测器需要同时处理小尺度定位、密集目标分离和复杂背景抑制等问题。VisDrone 是无人机目标检测任务中常用的数据集，覆盖 pedestrian、people、car、motor 等多类航拍目标，能够较好反映城市交通和低空巡检场景中的检测难点 [1, 5]。

小目标和密集目标会同时增加定位、分类和召回难度。一方面，小目标在深层特征图上的有效响应区域有限，容易在下采样过程中丢失边缘和纹理信息；另一方面，密集目标之间的边界接近，检测框重叠程度较高，后处理过程也可能影响最终召回。因此，在无人机航拍检测中，如何增强浅层空间信息并保持较高推理效率，是轻量化模型设计的重要问题。

2.2 YOLO 系列轻量化检测器

YOLO 系列方法以端到端检测和较快推理速度为主要特点，适合实时检测和边缘部署任务。对于无人机场景，轻量模型能够降低计算开销和存储成本，但也更容易受到特征容量和空间分辨率限制。本文选择 YOLO11n 作为基线，是因为其参数量较小、推理速度较快，便于在可接受复杂度下评估小目标增强策略。

轻量模型的主要问题在于深层特征图分辨率有限。经过多次下采样后，小目标在高层语义特征中的空间占比进一步降低，可能影响定位精度和召回率。因此，许多小目标检测改进会通过多尺度检测头、浅层特征融合或高分辨率输入来增强细粒度信息。本文的 P2 分支设计即沿着这一思路，将更高空间分辨率的浅层特征引入检测输出。

2.3 小目标检测增强策略

小目标检测常见增强策略包括高分辨率输入、多尺度检测头、浅层特征融合、注意力机制和数据增强等。高分辨率输入能够直接增加小目标在原图中的像素占比，通常对航拍小目标检测较为关键；多尺度检测头和浅层特征融合则试图在网络内部保留更多细粒度空间信息。

注意力机制能够通过重新分配特征响应提升网络表达能力。CoordAttention 将位置信息嵌入通道注意力建模过程，在保持轻量化的同时引入方向感知和位置敏感特征表达 [2]。对于无人机图像中的小目标、密集目标和复杂背景，该机制可能有助于增强目标区域响应。不过，注意力模块的实际收益需要结合消融结果谨慎判断。本文实验显示，CoordAttention 在 P2 基础上带来的是小幅补充提升，而非主要增益来源。

数据增强也可能影响小目标检测效果，例如 mosaic 关闭时机、缩放范围、copy-paste 和 erasing 等设置均会改变训练样本分布。本文保留小目标友好增强作为训练策略消融，但当前结果显示该策略未超过 YOLO11n-P2-CA，说明增强策略需要与数据集分布和模型结构进一步匹配。

3 方法

本文方法以 YOLO11n 为基础，整体包含三项设计：第一，引入 P2 高分辨率检测分支，使检测输出由原始 P3/P4/P5 扩展为 P2/P3/P4/P5；第二，在特征融合分支中加入 CoordAttention，以较低额外开销补充方向位置敏感建模；第三，在 YOLO11n-P2-CA 基础上采用 960 输入分辨率进行

高分辨率小目标检测实验。整体设计仍保持轻量化模型规模，具体结构差异如表 1 所示。

表 1 YOLO11n 与改进模型的结构差异对比

模块	原始 YOLO11n	改进模型
检测尺度	P3/P4/P5	P2/P3/P4/P5
小目标特征	主要依赖较深层特征	引入浅层高分辨率特征
注意力模块	无	在特征融合分支后加入 CoordAttention
输入尺寸	640	960
输出目标	常规实时检测	面向无人机小目标检测的精度-速度折中




图 1 YOLO11n-P2-CA-960 结构示意图

3.1 P2 高分辨率检测分支

原始 YOLO11n 主要依赖 P3/P4/P5 检测尺度。对于 VisDrone 中大量远距离行人、车辆和非机动车目标，目标在多次下采样后容易在深层特征图中丢失细节。为缓解该问题，本文在 YOLO11n 检测头中加入 P2 高分辨率检测分支，使模型能够利用更浅层、更高空间分辨率的特征进行预测。改进后模型采用 P2/P3/P4/P5 四尺度输出，从而提高小尺度目标在特征图中的可见性。具体实现配置见项目中的 `yolo11n_p2.yaml`。

3.2 CoordAttention 注意力增强

在 P2 模型基础上，本文进一步加入 CoordAttention 模块。CoordAttention 在建模通道关系的同时保留方向位置信息，有助于模型在复杂背景下补充位置敏感特征表达。对于无人机航拍图像中的小目标和密集目标，该模块可能增强目标区域与背景区域的区分能力。需要强调的是，结合后续消融结果，CoordAttention 带来的收益幅度有限，主要作为 P2 结构后的轻量级补充增强模块。具体实现配置见项目中的 `yolo11n_p2_coordatt.yaml`。

3.3 高分辨率输入与小目标友好增强

由于 VisDrone 中小目标占比较高，输入分辨率会直接影响目标在图像和中间特征图中的像素占比。本文在 YOLO11n-P2-CA 基础上测试 960 输入分辨率。当前实验结果显示，960 输入分辨率带来的提升最明显，是本文已完成实验中的主要增益来源。

此外，本文设计了小目标友好数据增强消融实验，设置包括 `close_mosaic: 20`、`scale: 0.35`、`copy_paste: 0.1` 和 `erasing: 0.0`。其中，较早关闭 mosaic 用于减少训练后期合成图像分布影响，较小 scale 用于降低小目标被过度缩小的风险，关闭 erasing 用于避免破坏小目标可见区域。当前结果显示该增强策略未超过 YOLO11n-P2-CA，因此本文仅将其作为训练策略消融进行讨论。

4 实验与分析

4.1 实验设置

实验基于 Ultralytics YOLO 框架，在 VisDrone2019-DET 数据集上进行。数据配置文件为 `configs/dataset/visdrone.yaml`，训练集、验证集和 test-dev 图像均转换为 YOLO 格式组织。所有已完成主实验均训练 100 个 epoch，并使用各实验输出目录中的 `results.csv` 统计最终指标与最佳指标。当前未获得 VisDrone 官方 test-dev/test-challenge 返回结果，因此本文仅报告验证集结果。

实验环境与训练配置如表 2 所示。表中版本信息由当前本地环境命令自动检测得到；训练轮数、输入尺寸、batch size、随机种子和优化器设置来自训练配置、`args.yaml` 或训练日志。

表 2 实验环境与训练配置

项目	设置
数据集	VisDrone2019-DET
训练轮数	100 epochs
输入尺寸	640 / 960
GPU	本地测速环境为 NVIDIA GeForce RTX 4060 Laptop GPU, 8 GB; 外部基线训练使用租用服务器 NVIDIA GeForce RTX 4090 D
CUDA 版本	12.8
Python 版本	3.12.7
PyTorch 版本	2.7.0+cu128
Ultralytics 版本	8.4.51
batch size	640 输入为 8, 960 输入为 4
optimizer	auto; 训练日志中由 Ultralytics 自动选择
初始学习率	lr0=0.01; 当 optimizer=auto 时由 Ultralytics 接管
预训练权重	YOLO11n 使用 <code>yolo11n.pt</code> ; P2 系列基于 <code>yolo11n.pt</code> 进行可匹配层初始化，新增层随机初始化
随机种子	42
验证图像处理	按 Ultralytics 验证流程进行 <code>resize/letterbox</code> 处理
NMS 设置	采用 Ultralytics 默认验证流程; 现有日志记录 <code>conf=None, iou=0.7, agnostic_nms=False</code>
速度测试	GPU 单图 <code>model.predict</code> wall-clock 计时, 10 次预热、100 张样本，并记录 Ultralytics <code>preprocess/inference/postprocess</code> 时间

4.2 主实验结果

表 3 给出了不同模型在 VisDrone 验证集上的检测结果。引入 P2 检测头后，最佳 mAP50 从 0.322 提升到 0.330，最佳 mAP50-95 从 0.182 提升到 0.190，说明浅层高分辨率特征对无人机小目标检测有一定帮助。加入 CoordAttention 后，最佳 mAP50 和 mAP50-95 分别达到 0.331 和 0.190，较 P2 模型继续小幅提升。进一步将输入尺寸提升至 960 后，YOLO11n-P2-CA-960 取得当前已完成 YOLO11n 主线实验中的最佳性能，mAP50 为 0.420，mAP50-95 为 0.252。该结果表明，在当前实验设置下，高分辨率输入是性能提升的主要来源。

表 3 不同模型在 VisDrone 验证集上的检测结果对比

方法	输入尺寸	Params/M	GFLOPs@640	P	R	mAP50	mAP50-95
YOLO11n	640	2.592	6.5	0.454	0.339	0.322	0.182
YOLO11n-P2	640	2.894	10.7	0.448	0.355	0.330	0.190
YOLO11n-P2-CA	640	2.904	10.7	0.454	0.350	0.331	0.190
YOLO11n-P2-CA-960	960	2.904	10.7	0.534	0.428	0.420	0.252
YOLO11n-P2-CA-SmallObjAug	640	2.904	10.7	0.452	0.348	0.328	0.187

表中 GFLOPs@640 表示模型结构在 640 输入尺寸下的统计结果。对于 960 输入实验，实际计算量会随输入分辨率增加；由于当前已有日志仅可靠记录 640 统计值，本文不将 10.7 GFLOPs 表述为 960 输入下的实际计算量。

4.3 外部参考基线对比

为避免仅在 YOLO11n 内部进行比较带来的局限，本文补充训练了 YOLOv8n 和 YOLO11s 两个外部参考基线，结果如表 4 所示。其中，YOLOv8n 用于提供常见轻量 YOLO 模型参考，YOLO11s 用于观察更大模型容量对 VisDrone 验证集结果的影响。需要说明的是，表 4 并不作为 P2 分支、CoordAttention 或 960 输入分辨率的单因素消融依据，因为这些模型在基础架构、参数量和输入设置上并不完全一致。

从结果看，YOLOv8n 与 YOLO11n 的性能接近，其最佳 mAP50 和 mAP50-95 分别为 0.325 和 0.184，略高于 YOLO11n 的 0.322 和 0.182。YOLO11s 的最佳 mAP50 和 mAP50-95 分别达到 0.389 和 0.227，明显高于 nano 级基线，说明增加模型容量能够提升 VisDrone 检测精度。但 YOLO11s 的参数量约为 9.432M，高于 YOLO11n-P2-CA-960 的 2.904M；而 YOLO11n-P2-CA-960 在更高输入分辨率下取得 0.420 mAP50 和 0.252 mAP50-95。该结果说明本文最终模型体现的是结构增强与高分辨率输入共同作用下的整体效果，而不能简单解释为单个模块相对外部基线的绝对优势。

表 4 外部参考基线在 VisDrone 验证集上的结果

方法	输入尺寸	Params/M	GFLOPs@640	P	R	mAP50 / mAP50-95
YOLOv8n baseline	640	3.013	8.2	0.448	0.346	0.325 / 0.184
YOLO11s baseline	640	9.432	21.6	0.524	0.393	0.389 / 0.227
YOLO11n baseline	640	2.592	6.5	0.454	0.339	0.322 / 0.182
YOLO11n-P2-CA-960	960	2.904	10.7	0.534	0.428	0.420 / 0.252




图 2 YOLO11n-P2-CA-960 训练与验证曲线

4.4 消融实验

表 5 展示了各改进项相对基线模型的贡献。P2 分支带来 0.009 的 mAP50 提升和 0.008 的 mAP50-95 提升，说明浅层高分辨率特征对小目标检测具有积极作用。CoordAttention 在 P2 基础上继续带来小幅提升，但提升幅度有限，说明其更适合作为补充增强模块。960 输入分辨率带来的提升最明显，相对基线 mAP50 提升 9.84 个百分点，mAP50-95 提升 6.94 个百分点，进一步说明高分辨率输入是当前实验设置下性能提升的主要来源。小目标友好增强相较基线有一定提升，但未超过 P2 和 YOLO11n-P2-CA，表明该增强策略在当前超参数下并非最优。

表 5 改进模块消融实验结果

方法	改动	输入尺寸	mAP50	Δ mAP50	mAP50-95	Δ mAP50-95
YOLO11n	基线模型	640	0.322	+0.000	0.182	+0.000
YOLO11n-P2	增加 P2 检测头	640	0.330	+0.009	0.190	+0.008
YOLO11n-P2-CA	增加 CoordAttention	640	0.331	+0.009	0.190	+0.008
YOLO11n-P2-CA-960	输入尺寸提升至 960	960	0.420	+0.098	0.252	+0.069
YOLO11n-P2-CA-SmallObjAug	小目标友好增强	640	0.328	+0.006	0.187	+0.005

4.5 类别级结果分析

项目中已整理每类指标和验证日志，因此本文进一步给出 YOLO11n-P2-CA-960 的类别级结果，如表 6 所示。car、bus 和 motor 等类别的 mAP50 相对较高，说明在目标外观较稳定或实例数量较多时模型更容易学习有效特征。bicycle、tricycle 和 awning-tricycle 的 mAP50 较低，可能与非机动车在俯视视角下外观相似、实例尺度较小和遮挡较多有关。pedestrian 与 people 两类也存在一定混淆风险，这与人体目标在航拍视角下尺度小、姿态信息不足有关。

表 6 YOLO11n-P2-CA-960 在 VisDrone 验证集上的类别级结果

类别	图像数	实例数	P	R	mAP50	mAP50-95
pedestrian	520	8844	0.580	0.501	0.513	0.243
people	482	5125	0.586	0.379	0.393	0.157
bicycle	364	1287	0.335	0.221	0.171	0.076
car	515	14064	0.736	0.830	0.837	0.590
van	421	1975	0.528	0.460	0.455	0.321
truck	266	750	0.538	0.395	0.375	0.249
tricycle	337	1045	0.435	0.317	0.268	0.155
awning-tricycle	220	532	0.300	0.198	0.133	0.086
bus	131	251	0.726	0.518	0.546	0.408
motor	485	4886	0.568	0.543	0.520	0.239

4.6 推理速度与模型复杂度

表 7 给出了不同模型的复杂度和推理速度。所有速度结果均由 `tools/benchmark_speed.py` 在同一台本地 GPU 上重新测试得到，采用单图 `model.predict` wall-clock 计时，包含预处理、推理和后处理开销。原始 YOLO11n 的平均延迟为 40.09 ms，FPS 为 24.94。YOLO11n-P2-CA 在 640 输入下平均延迟为 45.77 ms，FPS 为 21.85，说明 P2 分支和注意力模块会带来一定额外开销。YOLO11n-P2-CA-960 的平均延迟为 50.81 ms，FPS 为 19.68。虽然 960 输入降低了推理速度，但其验证集精度提升更明显，因此更适合对小目标检测精度要求较高且仍需保持一定推理效率的场景。

表 7 不同模型复杂度与推理速度对比

方法	输入尺寸	Params/M	GFLOPs@640	权重/MB	平均延迟/ms	FPS
YOLOv8n baseline	640	3.013	8.2	5.95	42.29	23.65
YOLO11s baseline	640	9.432	21.6	18.28	38.97	25.66
YOLO11n	640	2.592	6.5	5.21	40.09	24.94
YOLO11n-P2	640	2.894	10.7	5.91	43.64	22.91
YOLO11n-P2-CA	640	2.904	10.7	5.94	45.77	21.85
YOLO11n-P2-CA-SmallObjAug	640	2.904	10.7	5.94	49.96	20.02
YOLO11n-P2-CA-960	960	2.904	10.7	6.09	50.81	19.68

4.7 可视化分析

图 3 展示了 YOLO11n-P2-CA-960 在 VisDrone 验证集上的检测示例。模型在一般密集交通场景下能够检测出多类车辆、行人和非机动车目标。图 4 给出了复杂场景下的困难样例，可以观察到远距离极小目标、密集遮挡和类别外观相近仍可能导致漏检或误检。这些现象说明，尽管高分辨率输入和 P2 分支改善了小目标检测表现，复杂航拍场景中的极小目标召回和细粒度类别区分仍有进一步提升空间。



图 3 VisDrone 验证集密集交通场景检测示例

表 8 复杂场景中的典型误检与漏检原因分析

失败类型	可能原因
远距离极小目标漏检	目标像素过少，纹理和边缘信息不足
密集车辆遮挡	目标间距小，定位框重叠，NMS 后处理可能影响召回
pedestrian / people 混淆	俯视视角下人体外观差异较小，类别边界不清晰
bicycle / motor 混淆	非机动车在航拍视角下轮廓相似
背景误检	道路标识、树影或车辆局部纹理可能干扰分类




图 4 复杂场景下极小目标、密集遮挡和类别混淆示例

5 结论

本文针对无人机航拍小目标检测问题，在 YOLO11n 基础上构建并评估了结合 P2 高分辨率检测分支、CoordAttention 注意力机制和 960 输入分辨率的改进模型。实验结果表明，P2 分支能够增强浅层高分辨率特征利用，CoordAttention 在 P2 基础上带来一定但相对有限的补充提升，而 960 输入分辨率是当前实验设置中最主要的性能增益来源。最终，YOLO11n-P2-CA-960 在 VisDrone 验证集上取得最佳 mAP50 0.420 和 mAP50-95 0.252，并保持 19.68 FPS 的单图推理速度。外部基线结果显示，YOLO11s 作为更大容量模型能够显著提升检测精度，但本文最终模型在更小参数规模下结合高分辨率输入取得了更高验证集指标；该比较主要用于说明精度-速度-模型规模关系，而不作为单一模块有效性的直接证明。

当前结果说明，高分辨率输入对无人机小目标检测非常关键，轻量级 P2 分支和位置敏感注意力可以作为结构层面的辅助增强。后续工作可进一步探索更稳定的小目标损失函数、面向密集目标的后处理优化以及官方测试集评估，以增强方法在不同评测协议下的说服力。

参考文献

- [1] Du D, Zhu P, Wen L, et al. VisDrone-DET2019: The Vision Meets Drone Object Detection in Image Challenge[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. 2019.
- [2] Hou Q, Zhou D, Feng J. Coordinate Attention for Efficient Mobile Network Design[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 13713–13722.
- [3] Khanam R, Hussain M. YOLOv11: An Overview of the Key Architectural Enhancements[EB/OL]. arXiv:2410.17725, 2024.
- [4] Ultralytics. YOLO11 Documentation[EB/OL]. <https://docs.ultralytics.com/models/yolo11/>.
- [5] Ultralytics. VisDrone Dataset Documentation[EB/OL]. <https://docs.ultralytics.com/datasets/detect/visdrone/>.